加微信:642945106 发送"赠送"领取赠送精品课程

■ 发数字"2"获取众筹列表

「载APP

(2)

17 | 案例篇:如何利用系统缓存优化程序的运行效率?

2018-12-28 倪朋飞

Linux性能优化实战 进入课程 >



讲述:冯永吉 时长 15:30 大小 14.20M



你好,我是倪朋飞。

上一节,我们学习了内存性能中 Buffer 和 Cache 的概念。简单复习一下,Buffer 和 Cache 的设计目的,是为了提升系统的 I/O 性能。它们利用内存,充当起慢速磁盘与快速 CPU 之间的桥梁,可以加速 I/O 的访问速度。

Buffer 和 Cache 分别缓存的是对磁盘和文件系统的读写数据。

从写的角度来说,不仅可以优化磁盘和文件的写入,对应用程序也有好处,应用程序可以 在数据真正落盘前,就返回去做其他工作。

从读的角度来说,不仅可以提高那些频繁访问数据的读取速度,也降低了频繁 I/O 对磁盘的压力。

既然 Buffer 和 Cache 对系统性能有很大影响,那我们在软件开发的过程中,能不能利用这一点,来优化 I/O 性能,提升应用程序的运行效率呢?

答案自然是肯定的。今天,我就用几个案例帮助你更好地理解缓存的作用,并学习如何充分利用这些缓存来提高程序效率。

为了方便你理解, Buffer 和 Cache 我仍然用英文表示, 避免跟"缓存"一词混淆。而文中的"缓存", 通指数据在内存中的临时存储。

缓存命中率

在案例开始前,你应该习惯性地先问自己一个问题,你想要做成某件事情,结果应该怎么评估?比如说,我们想利用缓存来提升程序的运行效率,应该怎么评估这个效果呢?换句话说,有没有哪个指标可以衡量缓存使用的好坏呢?

我估计你已经想到了,**缓存的命中率**。所谓缓存命中率,是指直接通过缓存获取数据的请求次数,占所有数据请求次数的百分比。

命中率越高,表示使用缓存带来的收益越高,应用程序的性能也就越好。

实际上,缓存是现在所有高并发系统必需的核心模块,主要作用就是把经常访问的数据(也就是热点数据),提前读入到内存中。这样,下次访问时就可以直接从内存读取数据,而不需要经过硬盘,从而加快应用程序的响应速度。

这些独立的缓存模块通常会提供查询接口,方便我们随时查看缓存的命中情况。不过 Linux 系统中并没有直接提供这些接口,所以这里我要介绍一下,cachestat 和 cachetop ,它们正是查看系统缓存命中情况的工具。

cachestat 提供了整个操作系统缓存的读写命中情况。

cachetop 提供了每个进程的缓存命中情况。

这两个工具都是 <u>bcc</u> 软件包的一部分,它们基于 Linux 内核的 eBPF (extended Berkeley Packet Filters) 机制,来跟踪内核中管理的缓存,并输出缓存的使用和命中情况。

这里注意,eBPF 的工作原理不是我们今天的重点,记住这个名字即可,后面文章中我们会详细学习。今天要掌握的重点,是这两个工具的使用方法。

使用 cachestat 和 cachetop 前,我们首先要安装 bcc 软件包。比如,在 Ubuntu 系统中,你可以运行下面的命令来安装:

目复制代码

- 1 sudo apt-key adv --keyserver keyserver.ubuntu.com --recv-keys 4052245BD4284CDD
- 2 echo "deb https://repo.iovisor.org/apt/xenial xenial main" | sudo tee /etc/apt/sources.
- 3 sudo apt-get update
- 4 sudo apt-get install -y bcc-tools libbcc-examples linux-headers-\$(uname -r)

注意: bcc-tools 需要内核版本为 4.1 或者更新的版本,如果你用的是CentOS,那就需要手动升级内核版本后再安装。

操作完这些步骤, bcc 提供的所有工具就都安装到 /usr/share/bcc/tools 这个目录中了。不过这里提醒你, bcc 软件包默认不会把这些工具配置到系统的 PATH 路径中, 所以你得自己手动配置:

1 \$ export PATH=\$PATH:/usr/share/bcc/tools

配置完,你就可以运行 cachestat 和 cachetop 命令了。比如,下面就是一个 cachestat 的运行界面,它以 1 秒的时间间隔,输出了 3 组缓存统计数据:

■ 复制代码

1	\$ cachestat 1 3					
2	TOTAL	MISSES	HITS	DIRTIES	BUFFERS_MB	CACHED_MB
3	2	0	2	1	17	279
4	2	0	2	1	17	279
5	2	0	2	1	17	279

你可以看到,cachestat 的输出其实是一个表格。每行代表一组数据,而每一列代表不同的缓存统计指标。这些指标从左到右依次表示:

```
TOTAL ,表示总的 I/O 次数;
MISSES ,表示缓存未命中的次数;
HITS ,表示缓存命中的次数;
DIRTIES ,表示新增到缓存中的脏页数;
BUFFERS_MB 表示 Buffers 的大小 ,以 MB 为单位;
CACHED_MB 表示 Cache 的大小 ,以 MB 为单位。
```

接下来我们再来看一个 cachetop 的运行界面:

它的输出跟 top 类似,默认按照缓存的命中次数(HITS)排序,展示了每个进程的缓存命中情况。具体到每一个指标,这里的 HITS、MISSES 和 DIRTIES ,跟 cachestat 里的含义一样,分别代表间隔时间内的缓存命中次数、未命中次数以及新增到缓存中的脏页数。

而 READ_HIT 和 WRITE_HIT , 分别表示读和写的缓存命中率。

指定文件的缓存大小

除了缓存的命中率外,还有一个指标你可能也会很感兴趣,那就是指定文件在内存中的缓存大小。你可以使用 pcstat 这个工具,来查看文件在内存中的缓存大小以及缓存比例。

pcstat 是一个基于 Go 语言开发的工具,所以安装它之前,你首先应该安装 Go 语言,你可以点击这里下载安装。

安装完 Go 语言,再运行下面的命令安装 pcstat:

```
$ export GOPATH=~/go
$ sexport PATH=~/go/bin:$PATH
$ go get golang.org/x/sys/unix
$ go get github.com/tobert/pcstat/pcstat
```

全部安装完成后,你就可以运行 pcstat 来查看文件的缓存情况了。比如,下面就是一个 pcstat 运行的示例,它展示了 /bin/ls 这个文件的缓存情况:

这个输出中,Cached 就是 /bin/ls 在缓存中的大小,而 Percent 则是缓存的百分比。你看到它们都是 0,这说明 /bin/ls 并不在缓存中。

接着,如果你执行一下 ls 命令,再运行相同的命令来查看的话,就会发现/bin/ls 都在缓存中了:

知道了缓存相应的指标和查看系统缓存的方法后,接下来,我们就进入今天的正式案例。

跟前面的案例一样,今天的案例也是基于 Ubuntu 18.04,当然同样适用于其他的 Linux 系统。

机器配置: 2 CPU, 8GB 内存。

预先按照上面的步骤安装 bcc 和 pcstat 软件包,并把这些工具的安装路径添加到到PATH 环境变量中。

预先安装 Docker 软件包,比如 apt-get install docker.io

案例一

第一个案例, 我们先来看一下上一节提到的 dd 命令。

dd 作为一个磁盘和文件的拷贝工具,经常被拿来测试磁盘或者文件系统的读写性能。不过,既然缓存会影响到性能,如果用 dd 对同一个文件进行多次读取测试,测试的结果会怎么样呢?

我们来动手试试。首先,打开两个终端,连接到 Ubuntu 机器上,确保 bcc 已经安装配置成功。

然后,使用 dd 命令生成一个临时文件,用于后面的文件读取测试:

■ 复制代码

- 1 # 生成一个 512MB 的临时文件
- 2 \$ dd if=/dev/sda1 of=file bs=1M count=512
- 3 # 清理缓存
- 4 \$ echo 3 > /proc/sys/vm/drop_caches

继续在第一个终端,运行 pcstat 命令,确认刚刚生成的文件不在缓存中。如果一切正常,你会看到 Cached 和 Percent 都是 0:

■ 复制代码

```
1 $ pcstat file
2 +----+
3 | Name | Size (bytes) | Pages | Cached | Percent |
4 |-----+
5 | file | 536870912 | 131072 | 0 | 000.000 |
```

6 +-----+ **√**

还是在第一个终端中,现在运行 cachetop 命令:

■ 复制代码

1 # 每隔 5 秒刷新一次数据

2 \$ cachetop 5

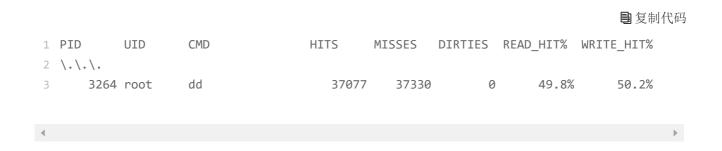
这次是第二个终端,运行 dd 命令测试文件的读取速度:



从 dd 的结果可以看出,这个文件的读性能是 33.4 MB/s。由于在 dd 命令运行前我们已经清理了缓存,所以 dd 命令读取数据时,肯定要通过文件系统从磁盘中读取。

不过,这是不是意味着, dd 所有的读请求都能直接发送到磁盘呢?

我们再回到第一个终端, 查看 cachetop 界面的缓存命中情况:



从 cachetop 的结果可以发现,并不是所有的读都落到了磁盘上,事实上读请求的缓存命中率只有 50%。

接下来,我们继续尝试相同的测试命令。先切换到第二个终端,再次执行刚才的 dd 命令:

```
■ 复制代码

1  $ dd if=file of=/dev/null bs=1M

2  512+0 records in

3  512+0 records out

4  536870912 bytes (537 MB, 512 MiB) copied, 0.118415 s, 4.5 GB/s
```

看到这次的结果,有没有点小惊讶?磁盘的读性能居然变成了 4.5 GB/s , 比第一次的结果明显高了太多。为什么这次的结果这么好呢?

不妨再回到第一个终端,看看 cachetop 的情况:

```
1 10:45:22 Buffers MB: 4 / Cached MB: 719 / Sort: HITS / Order: ascending
2 PID UID CMD HITS MISSES DIRTIES READ_HIT% WRITE_HIT%
3 \.\.\
4 32642 root dd 131637 0 0 100.0% 0.0%
```

显然, cachetop 也有了不小的变化。你可以发现,这次的读的缓存命中率是 100.0%, 也就是说这次的 dd 命令全部命中了缓存,所以才会看到那么高的性能。

然后,回到第二个终端,再次执行 pcstat 查看文件 file 的缓存情况:

从 pcstat 的结果你可以发现,测试文件 file 已经被全部缓存了起来,这跟刚才观察到的缓存命中率 100% 是一致的。

这两次结果说明,系统缓存对第二次 dd 操作有明显的加速效果,可以大大提高文件读取的性能。

但同时也要注意,如果我们把 dd 当成测试文件系统性能的工具,由于缓存的存在,就会导致测试结果严重失真。

案例二

接下来,我们再来看一个文件读写的案例。这个案例类似于前面学过的不可中断状态进程的例子。它的基本功能比较简单,也就是每秒从磁盘分区/dev/sda1中读取 32MB 的数据,并打印出读取数据花费的时间。

为了方便你运行案例,我把它打包成了一个 <u>Docker 镜像</u>。 跟前面案例类似,我提供了下面两个选项,你可以根据系统配置,自行调整磁盘分区的路径以及 I/O 的大小。

- -d 选项,设置要读取的磁盘或分区路径,默认是查找前缀为/dev/sd 或者/dev/xvd的磁盘。
- -s 选项,设置每次读取的数据量大小,单位为字节,默认为 33554432(也就是 32MB)。

这个案例同样需要你开启两个终端。分别 SSH 登录到机器上后,先在第一个终端中运行 cachetop 命令:

■ 复制代码

1 # 每隔 5 秒刷新一次数据

2 \$ cachetop 5

接着,再到第二个终端,执行下面的命令运行案例:

■复制代码

1 \$ docker run --privileged --name=app -itd feisky/app:io-direct

案例运行后,我们还需要运行下面这个命令,来确认案例已经正常启动。如果一切正常,你应该可以看到类似下面的输出:

```
1 $ docker logs app
2 Reading data from disk /dev/sdb1 with buffer size 33554432
3 Time used: 0.929935 s to read 33554432 bytes
4 Time used: 0.949625 s to read 33554432 bytes

▶
```

从这里你可以看到,每读取 32 MB 的数据,就需要花 0.9 秒。这个时间合理吗?我想你第一反应就是,太慢了吧。那这是不是没用系统缓存导致的呢?

我们再来检查一下。回到第一个终端,先看看 cachetop 的输出,在这里,我们找到案例进程 app 的缓存使用情况:

```
1 16:39:18 Buffers MB: 73 / Cached MB: 281 / Sort: HITS / Order: ascending
2 PID UID CMD HITS MISSES DIRTIES READ_HIT% WRITE_HIT%
3 21881 root app 1024 0 0 100.0% 0.0%

◆
```

这个输出似乎有点意思了。1024次缓存全部命中,读的命中率是100%,看起来全部的读请求都经过了系统缓存。但是问题又来了,如果真的都是缓存I/O,读取速度不应该这么慢。

不过,话说回来,我们似乎忽略了另一个重要因素,每秒实际读取的数据大小。HITS 代表缓存的命中次数,那么每次命中能读取多少数据呢?自然是一页。

前面讲过,内存以页为单位进行管理,而每个页的大小是 4KB。所以,在 5 秒的时间间隔里,命中的缓存为 1024*4K/1024 = 4MB,再除以 5 秒,可以得到每秒读的缓存是0.8MB,显然跟案例应用的 32 MB/s 相差太多。

至于为什么只能看到 0.8 MB 的 HITS, 我们后面再解释, 这里你先知道怎么根据结果来分析就可以了。

这也进一步验证了我们的猜想,这个案例估计没有充分利用系统缓存。其实前面我们遇到过 类似的问题,如果为系统调用设置直接 I/O 的标志,就可以绕过系统缓存。

那么,要判断应用程序是否用了直接 I/O,最简单的方法当然是观察它的系统调用,查找应用程序在调用它们时的选项。使用什么工具来观察系统调用呢?自然还是 strace。

继续在终端二中运行下面的 strace 命令,观察案例应用的系统调用情况。注意,这里使用了 pgrep 命令来查找案例进程的 PID 号:

```
# strace -p $(pgrep app)
strace: Process 4988 attached
restart_syscall(<\.\.\. resuming interrupted nanosleep \.\.\.>) = 0
openat(AT_FDCWD, "/dev/sdb1", O_RDONLY|O_DIRECT) = 4
mmap(NULL, 33558528, PROT_READ|PROT_WRITE, MAP_PRIVATE|MAP_ANONYMOUS, -1, 0) = 0x7f448d2
read(4, "8vq\213\314\264u\373\4\336K\224\25@\371\1\252\2\262\252q\221\n0\30\225bD\252\2€
write(1, "Time used: 0.948897 s to read 33"\.\.\., 45) = 45
close(4) = 0
```

从 strace 的结果可以看到,案例应用调用了 openat 来打开磁盘分区 /dev/sdb1,并且传入的参数为 O RDONLY|O DIRECT (中间的竖线表示或)。

O_RDONLY 表示以只读方式打开,而 O_DIRECT 则表示以直接读取的方式打开,这会绕过系统的缓存。

验证了这一点,就很容易理解为什么读 32 MB 的数据就都要那么久了。直接从磁盘读写的速度,自然远慢于对缓存的读写。这也是缓存存在的最大意义了。

找出问题后,我们还可以在再看看案例应用的源代码,再次验证一下:

```
■ 复制代码

1 int flags = O_RDONLY | O_LARGEFILE | O_DIRECT;

2 int fd = open(disk, flags, 0755);
```

上面的代码, 很清楚地告诉我们: 它果然用了直接 I/O。

找出了磁盘读取缓慢的原因,优化磁盘读的性能自然不在话下。修改源代码,删除 O_DIRECT 选项,让应用程序使用缓存 I/O ,而不是直接 I/O ,就可以加速磁盘读取速度。

app-cached.c 就是修复后的源码,我也把它打包成了一个容器镜像。在第二个终端中,按Ctrl+C 停止刚才的 strace 命令,运行下面的命令,你就可以启动它:

```
■复制代码

# 删除上述案例应用

$ docker rm -f app

# 运行修复后的应用

$ docker run --privileged --name=app -itd feisky/app:io-cached
```

还是第二个终端,再来运行下面的命令查看新应用的日志,你应该能看到下面这个输出:

```
1 $ docker logs app
2 Reading data from disk /dev/sdb1 with buffer size 33554432
3 Time used: 0.037342 s s to read 33554432 bytes
4 Time used: 0.029676 s to read 33554432 bytes

◆
```

现在,每次只需要 0.03 秒,就可以读取 32MB 数据,明显比之前的 0.9 秒快多了。所以,这次应该用了系统缓存。

我们再回到第一个终端,查看 cachetop 的输出来确认一下:

```
■复制代码

1 16:40:08 Buffers MB: 73 / Cached MB: 281 / Sort: HITS / Order: ascending

2 PID UID CMD HITS MISSES DIRTIES READ_HIT% WRITE_HIT%

3 22106 root app 40960 0 0 100.0% 0.0%
```

果然,读的命中率还是 100%, HITS (即命中数)却变成了 40960,同样的方法计算一下,换算成每秒字节数正好是 32 MB(即 40960*4k/5/1024=32M)。

这个案例说明,在进行 I/O 操作时,充分利用系统缓存可以极大地提升性能。 但在观察缓存命中率时,还要注意结合应用程序实际的 I/O 大小,综合分析缓存的使用情况。

案例的最后,再回到开始的问题,为什么优化前,通过 cachetop 只能看到很少一部分数据的全部命中,而没有观察到大量数据的未命中情况呢?这是因为,cachetop 工具并不把直接 I/O 算进来。这也又一次说明了,了解工具原理的重要。

cachetop 的计算方法涉及到 I/O 的原理以及一些内核的知识,如果你想了解它的原理的话,可以点击这里查看它的源代码。

总结

Buffers 和 Cache 可以极大提升系统的 I/O 性能。通常,我们用缓存命中率,来衡量缓存的使用效率。命中率越高,表示缓存被利用得越充分,应用程序的性能也就越好。

你可以用 cachestat 和 cachetop 这两个工具,观察系统和进程的缓存命中情况。其中,

cachestat 提供了整个系统缓存的读写命中情况。

cachetop 提供了每个进程的缓存命中情况。

不过要注意, Buffers 和 Cache 都是操作系统来管理的,应用程序并不能直接控制这些缓存的内容和生命周期。所以,在应用程序开发中,一般要用专门的缓存组件,来进一步提升性能。

比如,程序内部可以使用堆或者栈明确声明内存空间,来存储需要缓存的数据。再或者,使用 Redis 这类外部缓存服务,优化数据的访问效率。

思考

最后,我想给你留下一道思考题,帮你更进一步了解缓存的原理。

今天的第二个案例你应该很眼熟,因为前面不可中断进程的文章用的也是直接 I/O 的例子,不过那次,我们是从 CPU 使用率和进程状态的角度来分析的。对比 CPU 和缓存这两个不同角度的分析思路,你有什么样的发现呢?

欢迎在留言区和我讨论,写下你的答案和收获,也欢迎你把这篇文章分享给你的同事、朋友。我们一起在实战中演练,在交流中进步。



© 版权归极客邦科技所有,未经许可不得传播售卖。页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 16 | 基础篇:怎么理解内存中的Buffer和Cache?

下一篇 18 | 案例篇:内存泄漏了,我该如何定位和处理?

精选留言 (60)





L 22

[D17打卡]

想不到Buffer 和 Cache还有专门的工具分析, 长见识了!

暂时只能在自己的机器上玩玩, 生产环境连root权限都没有,更别提升级CentOS内核版本了.

关于思考题,我是这样想的:...

展开٧

作者回复: 总结的很好, 其实两个思路都可以, 不过具体实践时可能会受限于可用的性能工具



说是0)

2.绕过了系统缓存,为什么缓存命中率还百分之百?

作者回复: 1. 预读, 2. 还有元数据缓存



渡渡鸟_lin...

凸 4

2019-01-01

补充下centos7使用yum 安装bcc-tools:

[root@centos-80 ~]# yum update

[root@centos-80 ~]# rpm --import https://www.elrepo.org/RPM-GPG-KEYelrepo.org && rpm -Uvh http://www.elrepo.org/elrepo-release-7.0-2.el7.elrepo.noarch.rpm...

展开٧



往事随风,...

L 4

2018-12-28

要是centos验证一下就好了,不同系统很多问题不一样,操作上遇到问题很奇怪

作者回复: 大部分案例我都在centos7验证了,不过文章中有些地方没有列出来详细的步骤,比如 安装或者升级软件包的步骤,这些其实都是些基本功了。如果碰到实在无法解决的问题,请具体 描述下。

L 3

xfan

2019-01-11

我没有遇到老师的情况,我的hits为40960而不是1024,刚好是32M,我可能是固态?



2019-01-04

L 3

请问第一次读50%的命中率如何解释呢?

展开~

作者回复: 预读





这里的direct i/o是不是上一节课里的直接操作磁盘的 "裸i/o" 呢?如果是的话是不是应该从buffer的角度分析实验二呢?

展开~

作者回复: 不是的,直接IO是跳过Buffer,裸IO是跳过文件系统(还是有buffer的)



凸 2

老师你好,第一个案列我有不太明白的地方。希望能得到老师的指教。

既然执行了 echo 3 > /proc/sys/vm/drop_cacches , 为什么在dd if=file of=/dev/null bs=1M 的时候 , 还有缓存能命中呢 ? 我得理解是这些数据应该都没有在缓存啊。

展开٧



凸 2

老师太厉害了,这个课程的价值远远高于这个价!!

展开٧



<u></u> 2

打卡day18

年终忙着各种总结,各种文字性东西,已经连着一礼拜12点之后下班了,再忙也要坚持跟着实践~ & & & &

展开~

作者回复: 追加油



心 1

23:16:27 Buffers MB: 14 / Cached MB: 284 / Sort: HITS / Order: ascending PID UID CMD HITS MISSES DIRTIES READ_HIT% WRITE_HIT%

2049 root dockerd 3 0 1 66.7% 0.0%

2064 root dockerd 3 0 1 66.7% 0.0%

展开~



心 1

[root@bogon ~]# cat /etc/redhat-release CentOS Linux release 7.3.1611 (Core)

[root@bogon ~]# docker ps...

展开~