

071 | 高级推荐模型之三：优化复杂目标函数

2018-03-16 洪亮劼

AI技术内参

[进入课程 >](#)



讲述：初明明

时长 06:08 大小 2.82M



周三我们讨论了协同矩阵分解，其主要思想就是解决多个两两关系的矩阵分解，并且希望能够建立隐变量之间的共享。

今天，我们来看一个稍微不一样的话题，那就是**如何优化更加复杂的目标函数**。

为什么需要复杂的目标函数

在介绍更复杂的目标函数之前，我们首先来回想一下，在之前的分享中，都接触到了哪些目标函数。

对于基于流行度或者相似度的推荐系统来说，其实并没有真正的目标函数的概念。这些推荐模型都是某种直观的“翻译”，这也导致了这些推荐系统很难直接使用在真实的应用中，往

往是被当作特性用在其他模型中。

基于信息的推荐系统，本质上就是监督学习在推荐系统中的应用。因为是监督学习，那自然就需要目标函数。这里，经常是对点击率或者购买率进行建模，也就是说，经常使用**二分类的目标函数**。

当我们使用矩阵分解的架构来对用户和物品的关系进行建模时，绝大多数情况下我们是在讨论**评分**。对于评分信息，常用的其实是**线性回归**（Linear Regression），也有学者使用**泊松回归**，因为泊松回归对于整数变量的建模要好于线性回归。当然了，矩阵分解也可以扩展到对点击率或者购买率的建模。

当年 Netflix 竞赛之后，Netflix 公司把获奖的矩阵分解拿来地进行实现，放入线上系统中，结果发现并没有本质性地提高推荐效果，这其实就和目标函数有关。虽然 Netflix 竞赛造就了矩阵分解等类似模型的流行，但是逐渐地，研究人员和工业界从业人员也意识到，**用户对物品的评分，并不是推荐系统需要优化的目标，也就是说目标函数“选错了”**。

那么，我们需要什么样的目标函数呢？

高级目标函数

直接对评分进行建模的最大问题，就是这和真实的推荐场景并不相符。不管是电商平台，还是新闻系统，我们并不是只在意用户对于某一些物品的评分。

真实的应用场景往往是这样的，用户打开应用，然后浏览一系列物品，由上往下进行翻阅，然后从中找到喜欢的物品。

这是不是很像我们在讨论搜索的时候，用户对于搜索结果的浏览？回忆一下，在搜索的场景中，我们首先输入关键字，然后搜索算法会返回一系列的结果。大多数情况下，我们会对返回的结果逐一检查。

在推荐场景下，我们虽然没有搜索关键词，但是整个从上往下的场景是类似的。

于是，我们就可以从搜索排序中得到启发，尝试对推荐结果进行排序。换句话说，我们并不在意用户的真实评分，或者我们是否能对用户和物品的喜好度进行完美估计，我们在意的是，**能否把用户可能喜欢的物品排到前面去**。

把搜索系统中的排序思想利用到推荐系统中，是推荐系统的一个重大进步，这也让推荐系统和真实场景逐渐挂钩。

那么，很直观的，要想更改推荐系统的行为，从评分的预测到排序学习，我们需要更改目标函数。

参考文献 [1] 中提出了一种叫**BPR**的方法，是把**配对法**引入到推荐系统中的一个重要工作。我们快速回忆一下已经在搜索系统中介绍过的“配对排序学习”。简单说来，配对法就是希望，对于某一个查询关键词来说，学习到每一对文档之间的关系，然后通过把所有的两两关系都预测正确，从而建立一个完整的排序结果。

很明显，在推荐系统的场景下，没有查询关键词，但是我们依然可以通过构造“**会话**”（Session）来学习排序。

简单来说，我们针对用户来到应用后产生的会话，对用户交互过的物品进行建模训练。我们期望能把有“正交互信息”的物品排到“负交互信息”的物品之前。

值得注意的是，和搜索不一样，推荐系统往往没有明确的反馈信息。意思就是，在搜索系统中，我们有已知的标签信息，也就是哪一个文档是“相关”的，哪一个是“不相关”的。然而，在推荐系统中我们并没有这样的信息。

因此，所有用户和物品的交互都是“**隐回馈**”（Implicit Feedback）。我们必须**依靠假设来找到相关的物品**。在这里，我们假定有正交互信息的物品是比其他物品更加相关。于是，正交互的物品的预测值要高。这里的“正交互”可以是点击、购买或者其他信息。这就是BPR的基本思路。

需要强调的一点是，BPR 仅仅是一种思路框架，我们可以应用到矩阵分解中，以及基于信息的推荐系统等不同的模型中。我们可以把矩阵分解中的对于评分的目标函数换成基于BPR的目标函数，也就是进行配对法训练，得到的推荐系统能够更好地对物品进行排序。

有了这个思路，我们就可以打开一系列的想法了。比如，我们在前面的搜索模块中讲过，其实还可以直接优化类似 NDCG、MAP 这样的指标。那能不能把这些想法也搬运到推荐系统中去呢？

简单的回答是，能。但是这个流程也不是那么显然易见的，毕竟我们没有直接的标签信息，而且一般来说，这些目标函数本身就已经很难优化了，我们还要嫁接到矩阵分解或者是分解机等模型上，这就会让优化的难度继续攀升。今天我们就展开讨论这部分内容了。

小结

今天我为你讲了推荐系统的另外一个问题，那就是目标函数。

一起来回顾下要点：第一，我们分析了为什么要关注目标函数，以评分为基础的目标函数的问题；第二，我们详细介绍了 BPR 这种非常经典的配对法的目标函数。

最后，给你留一个思考题，如果我们能够对所有物品的喜好度进行精准预测，是不是就不需要 BPR 了呢？学习排序和对物品喜好度的预测是完全不同的两件事，还是相互之间有联系呢？

欢迎你给我留言，和我一起讨论。

参考文献

1. Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. BPR: Bayesian personalized ranking from implicit feedback. Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence (UAI '09). AUAI Press, Arlington, Virginia, United States, 452-461, 2009.


AI 技术内参

你的360度人工智能信息助理

洪亮劼

Etsy 数据科学主管
前雅虎研究院资深科学家



新版升级：点击「 请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 070 | 高级推荐模型之二：协同矩阵分解

下一篇 072 | 推荐的Exploit和Explore算法之一：EE算法综述

精选留言 (2)

 写留言



林彦

2018-03-16



如果我们真地有所有用户对所有物品的喜好度的精准预测，特别是除了用户喜欢的程度，也能把用户真正不喜欢的和用户未注意到的情况区别开来，并且不考虑这么多数据量的训练性能影响，则这个point-wise模型可以用来根据评分大小作排序，可以不需要 BPR。不过实际环境中这种理想状态很难达到。

...

展开



微微一笑

2018-03-16



推荐系统一般分为召回模块和排序模块吧，前面说的矩阵分解属于召回 学习排序属于排序

模块