05-有序集合为何能同时支持点查询和范围查询?

你好,我是蒋德钧。

有序集合(Sorted Set)是Redis中一种重要的数据类型,它本身是集合类型,同时也可以支持集合中的元素带有权重,并按权重排序。

而曾经就有一位从事Redis开发的同学问我:为什么Sorted Set能同时提供以下两种操作接口,以及它们的复杂度分别是O(logN)+M和O(1)呢?

• ZRANGEBYSCORE: 按照元素权重返回一个范围内的元素。

• ZSCORE: 返回某个元素的权重值。

实际上,这个问题背后的本质是:**为什么Sorted Set既能支持高效的范围查询,同时还能以O(1)复杂度获取元素权重值?**

这其实就和Sorted Set底层的设计实现有关了。Sorted Set能支持范围查询,这是因为它的核心数据结构设计采用了跳表,而它又能以常数复杂度获取元素权重,这是因为它同时采用了哈希表进行索引。

那么,你是不是很好奇,Sorted Set是如何把这两种数据结构结合在一起的?它们又是如何进行协作的呢?今天这节课,我就来给你介绍下Sorted Set采用的双索引的设计思想和实现。理解和掌握这种双索引的设计思想,对于我们实现数据库系统是具有非常重要的参考价值的。

好,接下来,我们就先来看看Sorted Set的基本结构。

Sorted Set基本结构

要想了解Sorted Set的结构,就需要阅读它的代码文件。这里你需要注意的是,在Redis源码中,Sorted Set的代码文件和其他数据类型不太一样,它并不像哈希表的dict.c/dict.h,或是压缩列表的 ziplist.c/ziplist.h,具有专门的数据结构实现和定义文件。

Sorted Set的**实现代码在t_zset.c文件中**,包括Sorted Set的各种操作实现,同时Sorted Set相关的**结构定 义在server.h文件中**。如果你想要了解学习Sorted Set的模块和操作,注意要从t_zset.c和server.h这两个文件中查找。

好,在知道了Sorted Set所在的代码文件之后,我们可以先来看下它的结构定义。Sorted Set结构体的名称为zset,其中包含了两个成员,分别是哈希表dict和跳表zsl,如下所示。

```
typedef struct zset {
   dict *dict;
   zskiplist *zsl;
} zset;
```

在这节课一开始,我就说过Sorted Set这种同时采用跳表和哈希表两个索引结构的设计思想,是非常值得学习的。因为这种设计思想充分利用了跳表高效支持范围查询(如ZRANGEBYSCORE操作),以及哈希表高效

支持单点查询(如ZSCORE操作)的特征。这样一来,我们就可以在一个数据结构中,同时高效支持范围查询和单点查询,这是单一索引结构比较难达到的效果。

不过,既然Sorted Set采用了跳表和哈希表两种索引结构来组织数据,我们在实现Sorted Set时就会面临以下两个问题:

- 跳表或是哈希表中,各自保存了什么样的数据?
- 跳表和哈希表保存的数据是如何保持一致的?

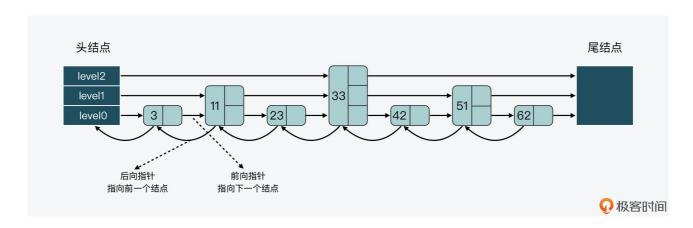
因为我已经在<mark>第3讲</mark>中给你介绍了Redis中哈希表的实现思路,所以接下来,我主要是给你介绍下跳表的设计和实现。通过学习跳表,你可以了解到跳表中保存的数据,以及跳表的常见操作。然后,我再带你来探究下Sorted Set如何将哈希表和跳表组合起来使用的,以及这两个索引结构中的数据是如何保持一致的。

跳表的设计与实现

首先,我们来了解下什么是跳表(skiplist)。

跳表其实是一种多层的有序链表。在课程中,为了便于说明,我把跳表中的层次从低到高排个序,最底下一层称为level0,依次往上是level1、level2等。

下图展示的是一个3层的跳表。其中,头结点中包含了三个指针,分别作为leve0到level2上的头指针。



可以看到,在level 0上一共有7个结点,分别是3、11、23、33、42、51、62,这些结点会通过指针连接起来,同时头结点中的level0指针会指向结点3。然后,在这7个结点中,结点11、33和51又都包含了一个指针,同样也依次连接起来,且头结点的level 1指针会指向结点11。这样一来,这3个结点就组成了level 1上的所有结点。

最后,结点33中还包含了一个指针,这个指针会指向尾结点,同时,头结点的level 2指针会指向结点33,这就形成了level 2,只不过level 2上只有1个结点33。

好,在对跳表有了直观印象后,我们再来看看跳表实现的具体数据结构。

跳表数据结构

我们先来看下跳表结点的结构定义,如下所示。

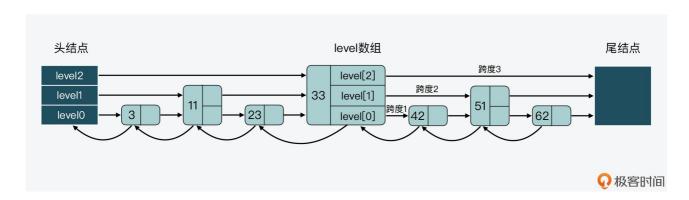
```
typedef struct zskiplistNode {
    //Sorted Set中的元素
    sds ele;
    //元素权重值
    double score;
    //后向指针
    struct zskiplistNode *backward;
    //节点的level数组,保存每层上的前向指针和跨度
    struct zskiplistLevel {
        struct zskiplistNode *forward;
        unsigned long span;
    } level[];
} zskiplistNode;
```

首先,因为Sorted Set中既要保存元素,也要保存元素的权重,所以对应到跳表结点的结构定义中,就对应了sds类型的变量ele,以及double类型的变量score。此外,为了便于从跳表的尾结点进行倒序查找,每个跳表结点中还保存了一个后向指针(*backward),指向该结点的前一个结点。

然后,因为跳表是一个多层的有序链表,每一层也是由多个结点通过指针连接起来的。因此在跳表结点的结构定义中,还包含了一个zskiplistLevel结构体类型的**level数组**。

level数组中的每一个元素对应了一个zskiplistLevel结构体,也对应了跳表的一层。而zskiplistLevel结构体 定义了一个指向下一结点的前向指针(*forward),这就使得结点可以在某一层上和后续结点连接起来。 同时,zskiplistLevel结构体中还定义了**跨度**,这是用来记录结点在某一层上的*forward指针和该指针指向的结点之间,跨越了level0上的几个结点。

我们来看下面这张图,其中就展示了33结点的level数组和跨度情况。可以看到,33结点的level数组有三个元素,分别对应了三层level上的指针。此外,在level数组中,level 2、level1和level 0的跨度span值依次是3、2、1。



最后,因为跳表中的结点都是按序排列的,所以,对于跳表中的某个结点,我们可以把从头结点到该结点的查询路径上,各个结点在所查询层次上的*forward指针跨度,做一个累加。这个累加值就可以用来计算该结点在整个跳表中的顺序,另外这个结构特点还可以用来实现Sorted Set的rank操作,比如ZRANK、ZREVRANK等。

好,了解了跳表结点的定义后,我们可以来看看跳表的定义。在跳表的结构中,定义了跳表的头结点和尾结点、跳表的长度,以及跳表的最大层数,如下所示。

```
typedef struct zskiplist {
    struct zskiplistNode *header, *tail;
    unsigned long length;
    int level;
} zskiplist;
```

因为跳表的每个结点都是通过指针连接起来的,所以我们在使用跳表时,只需要从跳表结构体中获得头结点或尾结点,就可以通过结点指针访问到跳表中的各个结点。

那么,当我们在Sorted Set中查找元素时,就对应到了Redis在跳表中查找结点,而此时,查询代码是否需要像查询常规链表那样,逐一顺序查询比较链表中的每个结点呢?

其实是不用的,因为这里的查询代码,可以使用跳表结点中的level数组来加速查询。

跳表结点查询

事实上,当查询一个结点时,跳表会先从头结点的最高层开始,查找下一个结点。而由于跳表结点同时保存了元素和权重,所以跳表在比较结点时,相应地有**两个判断条件**:

- 1. 当查找到的结点保存的元素权重,比要查找的权重小时,跳表就会继续访问该层上的下一个结点。
- 2. 当查找到的结点保存的元素权重,等于要查找的权重时,跳表会再检查该结点保存的SDS类型数据,是否比要查找的SDS数据小。如果结点数据小于要查找的数据时,跳表仍然会继续访问该层上的下一个结点。

但是,当上述两个条件都不满足时,跳表就会用到当前查找到的结点的level数组了。跳表会使用当前结点 level数组里的下一层指针,然后沿着下一层指针继续查找,这就相当于跳到了下一层接着查找。

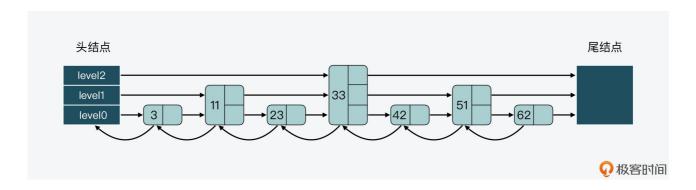
这部分的代码逻辑如下所示,因为在跳表中进行查找、插入、更新或删除操作时,都需要用到查询的功能,你可以重点了解下。

跳表结点层数设置

这样一来,有了level数组之后,一个跳表结点就可以在多层上被访问到了。而一个结点的level数组的层数也就决定了,该结点可以在几层上被访问到。

所以,当我们要决定结点层数时,实际上是要决定level数组具体有几层。

一种设计方法是,让每一层上的结点数约是下一层上结点数的一半,就像下面这张图展示的。第0层上的结点数是7,第1层上的结点数是3,约是第0层上结点数的一半。而第2层上的结点就33一个,约是第1层结点数的一半。

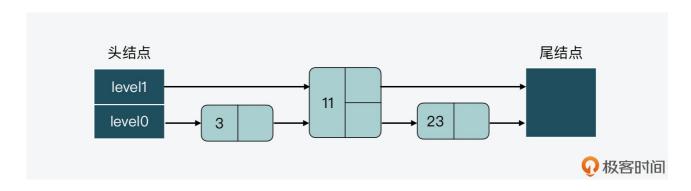


这种设计方法带来的好处是,当跳表从最高层开始进行查找时,由于每一层结点数都约是下一层结点数的一半,这种查找过程就类似于二分查找,**查找复杂度可以降低到O(logN)**。

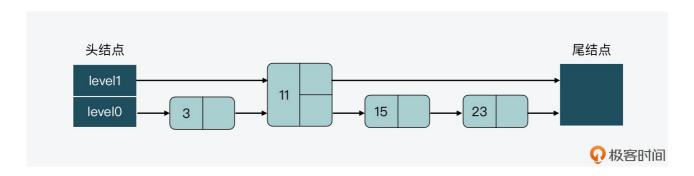
但这种设计方法也会带来负面影响,那就是为了维持相邻两层上结点数的比例为2:1,一旦有新的结点插入或是有结点被删除,那么插入或删除处的结点,及其后续结点的层数都需要进行调整,而这样就带来了额外的开销。

我先来给你举个例子,看下不维持结点数比例的影响,这样虽然可以不调整层数,但是会增加查询复杂度。

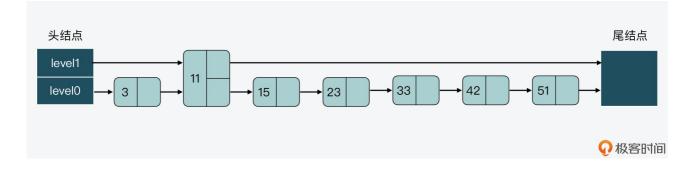
首先,假设当前跳表有3个结点,其数值分别是3、11、23,如下图所示。



接着,假设现在要插入一个结点15,如果我们不调整其他结点的层数,而是直接插入结点15的话,那么插入后,跳表level 0和level 1两层上的结点数比例就变成了为4:1,如下图所示。



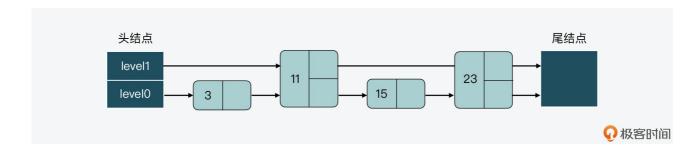
而假设我们持续插入多个结点,但是仍然不调整其他结点的层数,这样一来,level0上的结点数就会越来越多,如下图所示。



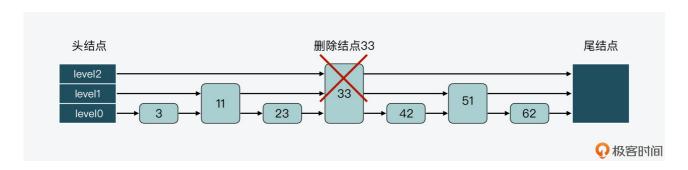
相应的,如果我们要查找大于11的结点,就需要在level 0的结点中依次顺序查找,复杂度就是O(N)了。所以,为了降低查询复杂度,我们就需要维持相邻层结点数间的关系。

好,接下来,我们再来看下维持相邻层结点数为2:1时的影响。

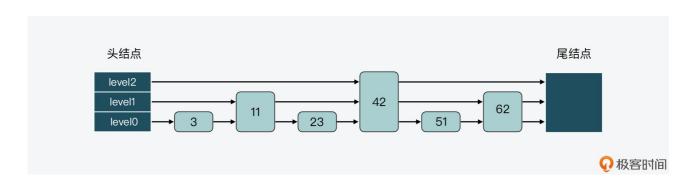
比如,我们可以把结点23的level数组中增加一层指针,如下图所示。这样一来,level 0和level 1上的结点数就维持在了2:1。但相应的代价就是,我们也需要给level数组重新分配空间,以便增加一层指针。



类似的,如果我们要在有7个结点的跳表中删除结点33,那么结点33后面的所有结点都要进行调整:



调整后的跳表如下图所示。你可以看到,结点42和62都要新增level数组空间,这样能分别保存3层的指针和 2层的指针,而结点51的level数组则需要减少一层。也就是说,这样的调整会带来额外的操作开销。



因此,为了避免上述问题,跳表在创建结点时,采用的是另一种设计方法,即**随机生成每个结点的层数**。此时,相邻两层链表上的结点数并不需要维持在严格的2:1关系。这样一来,当新插入一个结点时,只需要修改前后结点的指针,而其他结点的层数就不需要随之改变了,这就降低了插入操作的复杂度。

在Redis源码中,跳表结点层数是由**zslRandomLevel函数**决定。zslRandomLevel函数会把层数初始化为 1,这也是结点的最小层数。然后,该函数会生成随机数,如果随机数的值小于ZSKIPLIST_P(指跳表结点增加层数的概率,值为0.25),那么层数就增加1层。因为随机数取值到[0,0.25)范围内的概率不超过25%,所以这也就表明了,每增加一层的概率不超过25%。下面的代码展示了zslRandomLevel函数的执行逻辑,你可以看下。

```
#define ZSKIPLIST_MAXLEVEL 64 //最大层数为64
#define ZSKIPLIST_P 0.25 //随机数的值为0.25
int zslRandomLevel(void) {
    //初始化层为1
    int level = 1;
    while ((random()&0xFFFF) < (ZSKIPLIST_P * 0xFFFF))
        level += 1;
    return (level<ZSKIPLIST_MAXLEVEL) ? level : ZSKIPLIST_MAXLEVEL;
}
```

好,现在我们就了解了跳表的基本结构、查询方式和结点层数设置方法,那么下面我们接着来学习下, Sorted Set中是如何将跳表和哈希表组合起来使用的,以及是如何保持这两个索引结构中的数据是一致的。

哈希表和跳表的组合使用

其实,哈希表和跳表的组合使用并不复杂。

首先,我们从刚才介绍的Sorted Set结构体中可以看到,Sorted Set中已经同时包含了这两种索引结构,这就是组合使用两者的第一步。然后,我们还可以在Sorted Set的创建代码(<u>t_zset.c</u>文件)中,进一步看到跳表和哈希表被相继创建。

当创建一个zset时,代码中会相继调用**dictCreate函数**创建zset中的哈希表,以及调用**zslCreate函数**创建 跳表,如下所示。

```
zs = zmalloc(sizeof(*zs));
zs->dict = dictCreate(&zsetDictType, NULL);
zs->zs1 = zs1Create();
```

这样,在Sorted Set中同时有了这两个索引结构以后,接下来,我们要想组合使用它们,就需要保持这两个索引结构中的数据一致了。简单来说,这就需要我们在往跳表中插入数据时,同时也向哈希表中插入数据。

而这种保持两个索引结构一致的做法其实也不难,当往Sorted Set中插入数据时,zsetAdd函数就会被调用。所以,我们可以通过阅读Sorted Set的元素添加函数zsetAdd了解到。下面我们就来分析一下zsetAdd函数的执行过程。

• 首先,zsetAdd函数会判定Sorted Set采用的是ziplist还是skiplist的编码方式。

注意,在不同编码方式下,zsetAdd函数的执行逻辑也有所区别。这一讲我们重点关注的是skiplist的编码方式,所以接下来,我们就主要来看看当采用skiplist编码方式时,zsetAdd函数的逻辑是什么样的。

zsetAdd函数会先使用哈希表的dictFind函数,查找要插入的元素是否存在。如果不存在,就直接调用跳表元素插入函数zslInsert和哈希表元素插入函数dictAdd,将新元素分别插入到跳表和哈希表中。

这里你需要注意的是,Redis并没有把哈希表的操作嵌入到跳表本身的操作函数中,而是在zsetAdd函数中依次执行以上两个函数。这样设计的好处是保持了跳表和哈希表两者操作的独立性。

然后,如果zsetAdd函数通过dictFind函数发现要插入的元素已经存在,那么zsetAdd函数会判断是否要增加元素的权重值。

如果权重值发生了变化,zsetAdd函数就会调用zslUpdateScore函数,更新跳表中的元素权重值。紧接着,zsetAdd函数会把哈希表中该元素(对应哈希表中的key)的value指向跳表结点中的权重值,这样一来,哈希表中元素的权重值就可以保持最新值了。

下面的代码显示了zsetAdd函数的执行流程,你可以看下。

```
//如果采用ziplist编码方式时,zsetAdd函数的处理逻辑
if (zobj->encoding == OBJ_ENCODING_ZIPLIST) {
}
//如果采用skiplist编码方式时,zsetAdd函数的处理逻辑
else if (zobj->encoding == OBJ_ENCODING_SKIPLIST) {
       zset *zs = zobj->ptr;
      zskiplistNode *znode;
      dictEntry *de;
       //从哈希表中查询新增元素
       de = dictFind(zs->dict,ele);
       //如果能查询到该元素
       if (de != NULL) {
          /* NX? Return, same element already exists. */
          if (nx) {
              *flags |= ZADD NOP;
              return 1;
          }
          //从哈希表中查询元素的权重
          curscore = *(double*)dictGetVal(de);
          //如果要更新元素权重值
          if (incr) {
              //更新权重值
          }
          //如果权重发生变化了
          if (score != curscore) {
              znode = zslUpdateScore(zs->zsl, curscore, ele, score);
              //让哈希表元素的值指向跳表结点的权重
              dictGetVal(de) = &znode->score;
          }
          return 1;
      //如果新元素不存在
       else if (!xx) {
         ele = sdsdup(ele);
```

```
//新插入跳表结点
znode = zslInsert(zs->zsl,score,ele);
//新插入哈希表元素
serverAssert(dictAdd(zs->dict,ele,&znode->score) == DICT_OK);
...
return 1;
}
```

总之,你可以记住的是,Sorted Set先是通过在它的数据结构中同时定义了跳表和哈希表,来实现同时使用这两种索引结构。然后,Sorted Set在执行数据插入或是数据更新的过程中,会依次在跳表和哈希表中插入或更新相应的数据,从而保证了跳表和哈希表中记录的信息一致。

这样一来,Sorted Set既可以使用跳表支持数据的范围查询,还能使用哈希表支持根据元素直接查询它的权重。

小结

这节课,我给你介绍了Sorted Set数据类型的底层实现。Sorted Set为了能同时支持按照权重的范围查询,以及针对元素权重的单点查询,在底层数据结构上设计了**组合使用跳表和哈希表**的方法。

跳表是一个多层的有序链表,在跳表中进行查询操作时,查询代码可以从最高层开始查询。层数越高,结点数越少,同时高层结点的跨度会比较大。因此,在高层查询结点时,查询一个结点可能就已经查到了链表的中间位置了。

这样一来,跳表就会先查高层,如果高层直接查到了等于待查元素的结点,那么就可以直接返回。如果查到第一个大于待查元素的结点后,就转向下一层查询。下层上的结点数多于上层,所以这样可以在更多的结点中进一步查找待查元素是否存在。

跳表的这种设计方法就可以节省查询开销,同时,跳表设计采用随机的方法来确定每个结点的层数,这样就可以避免新增结点时,引起结点连锁更新问题。

此外,Sorted Set中还将元素保存在了哈希表中,作为哈希表的key,同时将value指向元素在跳表中的权重。使用了哈希表后,Sorted Set可以通过哈希计算直接查找到某个元素及其权重值,相较于通过跳表查找单个元素,使用哈希表就有效提升了查询效率。

总之,组合使用两种索引结构来对数据进行管理,比如Sorted Set中组合使用跳表和哈希表,这是一个很好的设计思路,希望你也能应用在日常的系统开发中。

每课一问

在使用跳表和哈希表相结合的双索引机制时,在获得高效范围查询和单点查询的同时,你能想到这种双索引机制有哪些不足之处吗?

精选留言:

- Kaito 2021-08-05 00:34:54
 - 1、ZSet 当数据比较少时,采用 ziplist 存储,每个 member/score 元素紧凑排列,节省内存

- 2、当数据超过阈值(zset-max-ziplist-entries、zset-max-ziplist-value)后,转为 hashtable + skiplist 存储,降低查询的时间复杂度
- 3、hashtable 存储 member->score 的关系,所以 ZSCORE 的时间复杂度为 O(1)
- 4、skiplist 是一个「有序链表 + 多层索引」的结构,把查询元素的复杂度降到了 O(logN),服务于 ZRAN GE/ZREVRANGE 这类命令
- 5、skiplist 的多层索引,采用「随机」的方式来构建,也就是说每次添加一个元素进来,要不要对这个元素建立「多层索引」?建立「几层索引」?都要通过「随机数」的方式来决定
- 6、每次随机一个 0-1 之间的数,如果这个数小于 0.25 (25% 概率),那就给这个元素加一层指针,持续随机直到大于 0.25 结束,最终确定这个元素的层数(层数越高,概率越低,且限制最多 64 层,详见 t_z et.c 的 zslRandomLevel 函数)
- 7、这个预设「概率」决定了一个跳表的内存占用和查询复杂度:概率设置越低,层数越少,元素指针越少,内存占用也就越少,但查询复杂会变高,反之亦然。这也是 skiplist 的一大特点,可通过控制概率,进而控制内存和查询效率
- 8、skiplist 新插入一个节点,只需修改这一层前后节点的指针,不影响其它节点的层数,降低了操作复杂度(相比平衡二叉树的再平衡,skiplist 插入性能更优)

关于 Redis 的 ZSet 为什么用 skiplist 而不用平衡二叉树实现的问题,原因是:

- skiplist 更省内存: 25% 概率的随机层数,可通过公式计算出 skiplist 平均每个节点的指针数是 1.33 个,平衡二叉树每个节点指针是 2 个(左右子树)
- skiplist 遍历更友好: skiplist 找到大于目标元素后,向后遍历链表即可,平衡树需要通过中序遍历方式来完成,实现也略复杂
- skiplist 更易实现和维护:扩展 skiplist 只需要改少量代码即可完成,平衡树维护起来较复杂

课后题:在使用跳表和哈希表相结合的双索引机制时,在获得高效范围查询和单点查询的同时,你能想到有哪些不足之处么?

这种发挥「多个数据结构」的优势,来完成某个功能的场景,最大的特点就是「空间换时间」,所以内存 占用多是它的不足。

不过也没办法,想要高效率查询,就得牺牲内存,鱼和熊掌不可兼得。

不过 skiplist 在实现时,Redis 作者应该也考虑到这个问题了,就是上面提到的这个「随机概率」,Redis 后期维护可以通过调整这个概率,进而达到「控制」查询效率和内存平衡的结果。当然,这个预设值是固定写死的,不可配置,应该是 Redis 作者经过测试和权衡后的设定,我们这里只需要知晓原理就好。 [15 赞]

• 陌 2021-08-05 09:56:20

skiplist + hashmap 实现的有序集合和常规的 double linked list + hashmap 所实现的 LRU 有些类似,都是使用链表结构进行核心的流程运转,hashmap 则是辅助链表使得能够在 O(1) 的时间复杂度内获取元素。这种组合式的数据结构还是很值得借鉴的。

leveldb 中也使用了 skiplist 来实现了 Memory Write Buffer,并且使用 CAS 操作实现了一个无锁的 skipli st,感兴趣的小伙伴也可以看看。实现上都差不多,都是使用 array + random 的方式存储和开辟新的层

Milittle 2021-08-06 00:41:44

补一条:如果用ziplist存储sorted set,那么zscore也是遍历查询的,这个可以从:void zaddCommand(client *c)一路看下去,这里说一点感想:大家如果不知道一个数据结构的创建,可以从redisCommandTable里面的命令函数一路看下去,可以找到不少东西。

• 曾轼麟 2021-08-06 00:15:07

首先回答老师提出的问题,索引机制有哪些不足之处? 首先我们知道(zset = dict + skiplist),那么可能会存在以下几个问题:

- 1、首先zset空间利用肯定是一大不足之处,毕竟是空间换时间
- 2、由于引入了dict,而dict底层是链式hash,当发生扩容的时候,对于整个zset其实是一种开销。
- 3、当zset进行大范围"有序"删除的时候开销会很大,跳表本身范围删除可以很快,本质可以只修改指针。但是当跳表删除后,还需要同步删除dict里面的数据,这时就会导致大开销了。(此外删除的时候有可能也会触发缩容rehash)

每次阅读老师的文章,都能有意外收获,本次阅读我得出以下的几个观点和结论:

- 1、redis作为一款优化到极致的中间件,不会单纯使用一种数据类型去实现一个功能,而会根据当前的情况选择最合适的数据结构,比如zset就是dict + skiplist,甚至当元素较少的时候zsetAdd方法会优先选择ziplist而不直接使用skiplist,以到达节约内存的效果(当小key泛滥的时候很有效果),当一种数据结构存在不足的情况下,可以通过和其它数据结构搭配来弥补自身的不足(软件设计没有银弹,只有最合适)。2、redis仰仗c语言指针的特性,通过层高level数组实现的skiplist从内存和效率上来说都是非常优秀的,我对比了JDK的ConcurrentSkipListMap的实现(使用了大量引用和频繁的new操作),指针的优势无疑
- 显现出来了 3、很多时候让我们感到惊艳的功能设计,可能本质只是一个很简单的原理,比如skiplist的随机率层高。 既保证每层的数量相对为下一层的一半,又保证了代码执行效率

最后借着评论我提出一个我发现的疑问:

我本次在阅读redis skiplist源码的时候,发现skiplist的最大层高上限,曾经在2020-02-02被 Murillo 大神修改过,从64修改成了32,但是我一直无法理解这一目的,在网上也没找到相应的答案,想问一下这个修改是出于什么样的目的呢?

- 胡玲玲 2021-08-05 15:51:07评论区都是神仙--
- 冷峰 2021-08-05 09:31:19双索引要使用更多的内存,只是以内存换时间
- Milittle 2021-08-05 01:49:41
 - 1. 多浪费了存储空间。
 - 2. 增加了编码的难度。
 - 3. 有可能会导致一个数据结构的数据更新了,但是另外一个没有更新的问题(可能概率较小,但是也有可能)