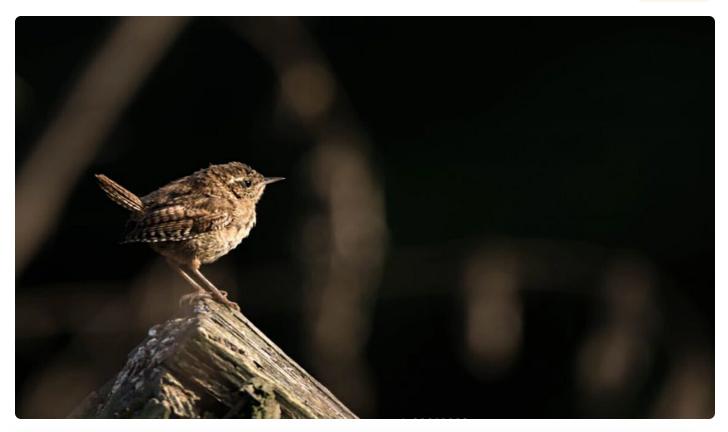
05 | Prometheus中有哪些关键设计?

2023-01-18 秦晓辉 来自北京

《运维监控系统实战笔记》





讲述:秦晓辉

时长 15:20 大小 14.01M



你好,我是秦晓辉。

上一讲我们介绍了如何搭建 Prometheus 系统,演示了基本的使用方法,这一讲我们深入进去,梳理一下 Prometheus 的关键设计,看看这些设计是如何奠定 Prometheus 江湖地位的。



标准先行,注重生态

Prometheus 最重要的规范就是**指标命名方式**,数据格式简单易读,在 **②**第 2 讲中我们已经聊过了,它用标签集来标识指标。有些监控系统会把一些特殊的字段单独提出来,最典型的就是hostname 字段,这种做法在一些特定场景会显得更有效。但是显然,**统一的标签集表达方式是最通用、最灵活的。**

虽然标签集很灵活,但是在实际落地时,我强烈建议你在公司推行一个标签定义规范,标签 Key 不能随便起名,该有的标签也不能缺失。既减少了理解成本,也保证了数据的规整完备, 便于后续做数据分析。比如,对于应用层面的监控,可以要求必须具备这几个信息。

• 指标名称 metric

Prometheus 内置建立的规范就是叫 metric(即 __name__)。如果是 Counter 类型,单调递增的值,指标名称以 _total 结尾。

• 服务名称 service

服务名称 service 要全局唯一,比如 n9e-webapi,p8s-alertmanager,一般是系统名称加上模块名称,组成最终的服务名称。如果公司比较大,就需要一个全局的服务目录做参考,否则不同的团队可能会起相同的名称,我们可以考虑使用 Git 里的 GroupName + RepoName。系统名称最好也单独做成一个标签,比如 system=n9e system=p8s。

• 实例名称 instance

一个服务一般会部署多个实例,可以直接使用机器名或 Pod 名作为 instance 名称_的如果在物面理机部署,有实例混部的情况,就要把端口加上,比如实例一是 **10.1.2.3**:3306,实例二是 **10.1.2.3**:3307。

• 服务类型 job

比如所有的 MySQL 的监控数据,都统一打上 job=mysql 的标签,Redis 的监控数据,就打上 job=redis 的标签。如果是自研的模块,也可以使用 webserver backend frontend 这种分类方式。

• 地域可用区 zone

把地域信息放到标签里,有个巨大的好处,比如某个 zone 出问题了,就比较容易看出来,带有某个特定的 zone 的指标数据异常,快速执行切流止损即可。有了 zone 的信息,region 就可有可无了,zone 的前缀一般就是 region。

• 集群名称 cluster

有的时候一个可用区会部署多个集群,特别是一些中间件,比如 ElasticSearch,给每个重要的业务单独部署一个集群,一个大公司可能有几百套 ElasticSearch 集群,几千套 ZooKeeper 集群。

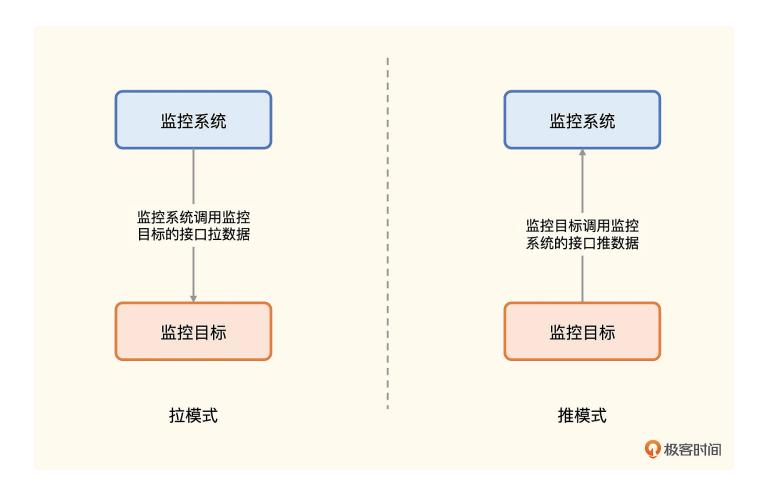
• 环境类型 env

环境类型 env 用来标识是生产环境还是测试环境。当然了,如果监控系统不复用(推荐这么做),生产用生产的监控系统,测试用测试的监控系统,就无需这个标签了。

指标的数据格式和传输协议制定好之后,各种 Exporter、各种支持 Remote Read/Write 的后端存储就可以接入进来了,而这些 Exporter、存储的丰富和繁荣,又反向推动了 Prometheus 的流行,形成正向循环。

主要使用拉模式,解耦

Prometheus 主要使用拉模式获取指标,辅以推模式(Pushgateway 的职能)。很多监控系统都是推模式,比如 Datadog、Open-Falcon、Telegraf+InfluxDB 组合。推拉两种方式,在监控领域讨论也比较多,它们各有优缺点和适用场景。



拉模式有个最重要的优势,就是解耦。你可能之前听很多人说过这个优势,但你未必能体会到解耦解在了哪里,我举一个例子你就懂了。

对于各类中间件,特别是非常基础的那些,很大概率是先于监控系统部署的。如果是拉模式,部署好监控系统之后,再来调用中间件的接口获取数据即可。如果是推模式,就需要在中间件里重新配置监控数据上报地址,然后重启中间件,这个代价就太高了。

但是拉模式需要有很好的服务发现机制,如果只有少量的几个目标要采集,怎么搞都可以,但是有几百个的时候,手工配置就比较麻烦了。所以 Prometheus 支持各种服务发现机制,尤其是基于 Kubernetes 的服务发现机制,是最常见的。

如果服务没有部署在 Kubernetes 中,而是部署在传统物理机或虚拟机上,这个时候就需要使用 Consul 之类的服务发现机制。但如果在监控体系建设之前,服务没有接入注册中心,为了满足监控需求而接入注册中心,用户会觉得成本太高。此时推模式就有了用武之地,这就是很多公司的自研服务都使用推模式发送监控数据的原因。

所以结论就来了:中间件类使用拉模式,自研的服务使用推模式,自研的服务如果都接入了注册中心,则也可以使用拉模式。

当然,推拉的选择还有一个点比较关键,就是**网络通路问题**,特别是网络 ACL 限制比较严格的环境,很多都是可出不可进,比如典型的 NAT 出网,这种情况下推模式的适配性更好,也就是说对 ACL 更友好一些。另一个关键点是**短周期任务或批处理任务**,通常不太可能监听HTTP 端口,这种大概率也是推模式。

推拉模式的选择,还有一些其他影响因素,比如推模式服务端通常比较容易处理,因为数据接收是无状态的。但是拉模式在数据量大的时候要考虑分片的问题,还有就是失联告警问题,拉模式很容易感知到目标失联。推模式就比较复杂了,需要对数据缺失做告警,比如Prometheus 的 absent 函数,absent 函数需要把指标的每个标签都写全,才能达到预期效果。而指标数量何止千万,几乎不可能完成。

最后就是可控性问题,拉模式,监控系统是主动的一方,可以控制频率,推模式,客户端是主动的一方,如果代码写"挫"了,就会给监控系统造成很大压力。

前面我们提到拉模式需要有很好的服务发现机制,Prometheus 采取的就是拉模式,因此它对 监控目标动态发现机制的苛求度很高。

监控目标动态发现机制

监控目标动态发现机制,这个问题其实很早就有,老一些的监控系统,比如 Zabbix,是资产管理式,要监控的目标都需要在服务端注册、配置。这种方式在监控目标偏静态的场景还是比较好用的,但是云原生之后,基础设施动态化,监控目标的创建、销毁都比较频繁,就需要有一个更自动化的机制来获取监控目标列表。

Prometheus 内置了多种服务发现机制,最常见的有四种。

- **基于配置文件的发现机制**:这种方式看起来很低端,其实非常常用,因为可以配合配置管理工具一起使用,非常方便。使用配置管理工具批量更新配置,然后让监控系统重新加载一下就可以了,比较丝滑。
- 基于 Kubernetes 的发现机制: Kubernetes 中有很多元信息,通过调用 kube-apiserver,可以轻易拿到 Pod、Node、Endpoint 等列表,Prometheus 内置支持了 Kubernetes 的服务发现机制,让这个过程变得更简单,Prometheus 基本成为了 Kubernetes 监控的标配。

- 基于公有云 API 的发现机制:比如要监控公有云上所有的 RDS 服务,一条一条配置比较麻烦,这个时候就可以基于公有云的 OpenAPI 做一个服务发现机制,自动拉取相关账号下所有 RDS 实例列表,大幅降低管理成本。
- 基于注册中心的发现机制: 社区里最为常用的是 Consul, 典型场景是 PING 监控和 HTTP 监控, 把所有目标注册到 Consul 中, 然后读取 Consul 生成监控对象列表即可。

这就是 Prometheus 支持的几个主要的服务发现机制,当然还有其他方式,但用得没那么多,这里就先不介绍了。

基于配置文件的管理方式

Prometheus 的告警规则管理、记录规则管理、抓取配置管理与发送策略管理,全部是基于配置文件的,这虽然不是一个关键设计,但确实是一个非常有特色的设计,我们也简单聊一下。

这个方式有两个好处,一个是简单,简单到令人发指,很多监控系统都是使用数据库来存储各类配置的,Prometheus则直接使用 Yaml 文件,非常直观。第二个好处就是便于自动化,配合配置管理工具、Git、Kubernetes等,与 Infrastructure as Code 的管理风潮非常契合。

当然,这样管理也有一个问题,就是不便于公司级协作,比如公司有 30 条业务线,数百个服务,上千个研发,大家都来管理一套配置,会非常混乱。所以很多公司的做法是由一个专职的运维团队来管理这套配置,其他业务线研发有需求了就给这个运维团队提工单,这种做法也凑合能用,只是苦了这个运维团队,团队成员比较容易产生焦躁情绪。

另外,Prometheus 默认是单机时序存储,容量有上限,基于配置管理的问题和容量问题,我个人非常建议那些推行 DevOps 的团队来使用,而且是每个团队自己有一套单独的 Prometheus,互不干扰,正所谓"You build it. You Run it. You monitor it. You own it."

当然,这样也会带来问题,最典型的是数据孤岛问题,不过我们可以把各个 Prometheus 中的核心关键指标抽取到一个统一的地方来呈现,比如使用 Prometheus 联邦机制,**只共享核心指标**,其余指标不需要抽取到中心,自己团队消化就好。

当然,后面第8讲我们也会使用 Nightingale 来增强 Prometheus 的配置管理问题,算是另一个思路。

灵活的查询语言

PromQL (Prometheus Query Language) 是 Prometheus 的查询语言,非常灵活。这也是 Prometheus 的一个关键设计。

很多老一代监控系统都只能对数据做简单过滤判断阈值,没有 QL 的支持。当我们想要某个数据却发现没有的时候,就天然倾向于在采集侧处理,但是**采集侧是无法穷举所有计算场景的,采集侧应该采集原始数据,后续的二次计算还是应该放到中心来搞定**。

比如机器的内存指标,我们可以从 cat /proc/meminfo 中看到很多内存相关的监控指标,采集器可以轻易拿到 MemAvailable 和 MemTotal 这样的字段,但是操作系统不会直接暴露内存可用率,此时就需要使用 PromQL: MemAvailable / MemTotal * 100 做二次计算了。因为这个场景很常见,有的采集器就直接自动做了计算,输出 mem_available_percent 这样的指标。但是还有很多场景是不好穷举的,下面我们再举个例子。

有一些监控数据的采集,是完全由用户配置出来的,比如 SNMP 数据采集,采集哪些 OID 是用户配置的; JMX 数据采集,采集哪些 MBean、哪些 Pattern 也是用户配置的。监控采集器压根就不知道这些数据的具体语义,只有配置采集规则的人知道,这种情况更不可能自动计算,采集器只能采集原始数据,如果有二次计算的需求,最好是设计到服务端,让服务端来做。

PromQL 为二次计算提供了能力支持,多个指标的关联计算、多条件联合告警,都可以用 PromQL 来实现,作为现代监控系统,Query Language 已经是必备要求了。

小结

这一讲,我们介绍了一些 Prometheus 的关键设计,这些设计成就了 Prometheus。下面我们对这一讲的内容做一个简单的回顾。

- Prometheus 非常注重标准制定和生态建设,而且标准很稳定,没有变来变去,社区有很多人参与其中,共建整套生态。Prometheus 不期望解决所有问题,但是影响力巨大,就是因为标准和生态的强大。
- Prometheus 主要使用拉模式,辅以推模式。我们比较了推拉两种模式,简单来看,拉模式便于解耦,推模式则更简单。中间件监控适合拉模式,自研模块适合推模式。当然,如果注册中心完备,服务都接入了注册中心,服务监控的数据采集也可以使用拉模式。

- 拉模式更需要监控目标动态发现机制,主要使用拉模型的 Prometheus 内置了多种发现机制,最常用的是基于配置文件、Kubernetes、公有云 API、Consul 四种发现机制。
- Prometheus 的配置管理非常简单,直接使用 Yaml 文件,很直观,便于推行 htc 管理模 com/式,只是在公司级大规模协同的时候会有些不方便。当然,国内的大部分企业没有践行 laC, Yaml 配置的方式会相对难搞一些。

天下无鱼

• Prometheus 查询语言就是 PromQL,这也是它最后一个关键设计,让采集侧专注采集,服务端提供灵活的计算能力,有些偏传统的企业难以接受这种做法,只想简单过滤指标来配置阈值,很难把 PromQL 的优势发挥出来,非常可惜。

最后,我整理了一张脑图,帮助你理解和记忆。



这一讲我们介绍了 Prometheus 的多个关键设计,弄懂这些内容非常重要,每个产品都有自己擅长的领域,我们要取各家所长为我所用。听我说了这么多,最后我也想听听你的看法和见解,你还知道 Prometheus 的哪些关键设计,哪些设计让你拍案叫绝或让你非常难受你就能要,com/

欢迎你留言分享,也欢迎你把今天的内容分享给身边的朋友,邀他一起学习。我们下一讲再见!

分享给需要的人, Ta购买本课程, 你将得 18 元

🕑 生成海报并分享

© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 04 | 如何快速搭建Prometheus系统?

下一篇 06 | PromQL有哪些常见的使用场景?

精选留言 (10)





叶夏

2023-01-19 来自江苏

可以把Prometheus的配置yaml和告警规则yaml单独放到一个代码仓库中,把这个仓库向有需要的人开放,如果他们想要添加某一个规则,就自己修改提交PR,提交PR的部署到测试环境,验证没有问题,prometheus owner 审核PR之后合并到master分支中,这个时候在自动部署到生产环境,我们是这么做的,感觉蛮好的

作者回复:

共2条评论>

<u>6</u> 10



Ishmael

2023-01-19 来自四川

我觉得最绝的还是限制值必须为float这点,限制死了之后保证了数据的高压缩度,进一步保证了计算性能和存储空间的节省。同时wal和分级存储也很绝,kv设计的思路也很不错。tag这个

设计在实际接入中帮了大忙。

作者回复: 天下元鱼 https://shikey.com/



那时刻

2023-01-18 来自北京

Prometheus 数据的存储按冷热数据进行分离,最近的数据肯定是看的最多的,所以缓存在内存里面,为了防止宕机而导致数据丢失因而引入 wal 来做故障恢复。数据超过一定量之后会从内存里面剥离出来以 chunk 的形式存放在磁盘上这就是 head chunk。对于更早的数据会进行压缩持久化变成 block 存放到磁盘中。

对于 block 中的数据由于是不会变的,数据较为固定,所以每个 block 通过 index 来索引其中的数据,并且为了加快数据的查询引用倒排索引,便于快速定位到对应的 chunk。

作者回复:



无名无姓

2023-01-18 来自北京

推和拉,有很大区别

<u>...</u>

凸 1



胡飞

2023-01-29 来自上海

在k8s模式下部署,配置采用yaml缺点就出来了,一套环境大家都有弄,改错了,甚至缩进写错了都会造成pod重启失败。后面采用servicemonitor/podmonitor 感觉就好多了

作者回复:



Geek a99361

2023-01-29 来自北京

Prometheus使用本地存储的方式有一些局限性,远端存储有什么推荐?比如 clickhouse或者i nfluxDB

作者回复: 后面的章节会介绍如何扩展Prometheus的存储,个人推荐VictoriaMetrics







telegraf是拉模式吗?telegraf中的各个plugin都要配置influxdb的地址,应该是push模式吧

	作者回复: 是推模式,不是各个plugin都配置infl址,只要配置一个output的plugin写入后端时序	uxdb的地址,所有input的plugin都无需配置influxdb地 库就可以了
	hshopeful 2023-01-19 来自湖北 基于gorilla的时序数据压缩算法很经典	
	作者回复:	
	∵	
peter 2023-01-18 来自北京 Q1: Prometheus是用什么开发的? JAVA吗? Q2: Prometheus代码规模有多大? 百万行代码?		
	作者回复: prometheus用go写的,我没做具体约	元 计,整体代码量不大
	∵	
	Ecoder	



Prometheus的数据模型和时序库也很经典



