18 | 组件监控: Kubernetes 控制面组件的关键指标与数据采集

2023-02-17 秦晓辉 来自北京

《运维监控系统实战笔记》

课程介绍 >



讲述:秦晓辉

时长 14:45 大小 13.47M



你好,我是秦晓辉。

上一讲我们介绍了 Kubernetes **工作负载节点**的监控,了解了 Kube-Proxy、Kubelet、容器负载监控的方法。这一讲我们介绍**控制面组件**的监控,包括 APIServer、Controller-manager(简称 CM)、Scheduler、etcd 四个组件,我会讲解这几个组件监控数据的采集方法和关键指标,并给出监控大盘。此外,我们还会学习如何使用 kube-state-metrics(简称 KSM)来监控 Kubernetes 的各类对象。

数据采集

自行搭建 Kubernetes 控制面的朋友,大都是选择 Kubeadm 这样的工具,Kubeadm 会把控制面的组件以静态容器的方式放到容器里运行,之后我会重点给你演示在这种部署方式下如何采集监控数据。

不过很多大一些的互联网公司会选择直接使用二进制的方式来部署,因为二进制的方式对于监控数据采集来说其实更简单,直接在采集器里配置要抓取的这几个组件的目标地址就可以了。

如果想要调用 Kubernetes 服务端 APIServer、Controller-manager、Scheduler 这三个组件的 /metrics 接口,需要有 Token 做鉴权,我们还是通过创建 ServiceAccount 的方式拿到 Token,后面也会把采集器直接部署到 Kubernetes 容器里,这样 Token 信息就可以自动 mount 到容器里,比较方便。

创建认证信息

相比前面为 Categraf 准备的 ServiceAccount,用于访问控制面组件的 ServiceAccount 会要求更多权限,这里我重新给出一个升级后的 YAML 文件,供你参考。

```
国 复制代码
2 apiVersion: rbac.authorization.k8s.io/v1
3 kind: ClusterRole
4 metadata:
5 name: categraf
6 rules:
    - apiGroups: [""]
     resources:
        - nodes
        nodes/metrics
        nodes/stats
        nodes/proxy
        - services
        - endpoints
14
         - pods
     verbs: ["get", "list", "watch"]
    - apiGroups:
       - extensions
        - networking.k8s.io
     resources:
        - ingresses
       verbs: ["get", "list", "watch"]
     - nonResourceURLs: ["/metrics", "/metrics/cadvisor"]
24
      verbs: ["get"]
25 ---
26 apiVersion: v1
27 kind: ServiceAccount
28 metadata:
29 name: categraf
30 namespace: flashcat
31 ---
32 apiVersion: rbac.authorization.k8s.io/v1
```

```
33 kind: ClusterRoleBinding
34 metadata:
35    name: categraf
36 roleRef:
37    apiGroup: rbac.authorization.k8s.io
38    kind: ClusterRole
39    name: categraf
40 subjects:
41 - kind: ServiceAccount
42    name: categraf
43    namespace: flashcat
```

使用 kubectl apply 一下这个 YAML 文件即可。有了认证信息,后面就是选型并部署采集器了。

部署采集器

我们希望能够自动感知到组件实例的变化,也就是要抓取的目标地址的变化。毫无疑问要读取 Kubernetes 的元信息,就需要具备类似 Prometheus 的 Kubernetes 服务发现能力。支持这个服务发现能力的采集器,比较常用的是 Telegraf、Prometheus、Categraf、Grafana-agent、vmagent 等,这里最原汁原味的显然是 Prometheus 自身。

Prometheus 从 v2.32.0 开始支持 agent mode 模式,相当于把 Prometheus 当做一个采集 agent 来使用,只负责采集数据,这个玩法最为简便清晰,我们就使用这个方式来采集数据。

agent mode 模式的 Prometheus,重点要配置 scrape 规则和 remote write 地址,我们把配置文件做成 ConfigMap,你可以看一下具体的 YAML 文件。

```
l apiVersion: v1
kind: ConfigMap
metadata:
name: prometheus-agent-conf
labels:
name: prometheus-agent-conf
namespace: flashcat
data:
prometheus.yml: |-
global:
scrape_interval: 15s
evaluation_interval: 15s
scrape_configs:
```

```
- job_name: 'apiserver'
           kubernetes_sd_configs:
           - role: endpoints
           scheme: https
           tls_config:
             insecure_skip_verify: true
           authorization:
             credentials_file: /var/run/secrets/kubernetes.io/serviceaccount/token
           relabel_configs:
           - source_labels: [__meta_kubernetes_namespace, __meta_kubernetes_servic
             action: keep
             regex: default;kubernetes;https
         - job_name: 'controller-manager'
           kubernetes_sd_configs:
           - role: endpoints
           scheme: https
           tls_config:
             insecure_skip_verify: true
           authorization:
             credentials_file: /var/run/secrets/kubernetes.io/serviceaccount/token
           relabel_configs:
           - source_labels: [__meta_kubernetes_namespace, __meta_kubernetes_servic
             action: keep
             regex: kube-system;kube-controller-manager;https
         - job_name: 'scheduler'
           kubernetes_sd_configs:
           - role: endpoints
           scheme: https
           tls_config:
             insecure_skip_verify: true
           authorization:
47
             credentials_file: /var/run/secrets/kubernetes.io/serviceaccount/token
           relabel_configs:
           - source_labels: [__meta_kubernetes_namespace, __meta_kubernetes_servic
             action: keep
             regex: kube-system;kube-scheduler;https
         - job_name: 'etcd'
           kubernetes_sd_configs:
           - role: endpoints
           scheme: http
           relabel_configs:
           - source_labels: [__meta_kubernetes_namespace, __meta_kubernetes_servic
             action: keep
             regex: kube-system;etcd;http
         - job_name: 'kube-state-metrics'
           kubernetes_sd_configs:
           - role: endpoints
           scheme: http
```

```
relabel_configs:
- source_labels: [__meta_kubernetes_namespace, __meta_kubernetes_servic
action: keep
regex: kube-system;kube-state-metrics;http-metrics
remote_write:
```

我来简单介绍一下,这段代码中包含了 5 个抓取 job,分别是 APIServer、Controller-manager、Scheduler、ectd、KSM。前面 3 个走的是 HTTPS ,后面两个走的是 HTTP,重点关注 relabel 规则。keep 的规则实际就是在做过滤,只过滤自己 job 感兴趣的那些endpoint。最后两行配置了 remote write 地址,采集到的数据通过 remote write 协议推给远端,我这里是推给了 n9e-server,n9e-server 后面是 VictoriaMetrics 集群。

准备好配置文件之后,接下来部署 Prometheus。因为只是抓取几个服务端组件,抓取量不大,不用做分片,我这里把 Prometheus agent mode 做成单副本的 Deployment,你可以看一下我给出的 YAML 文件。

```
国 复制代码
1 apiVersion: apps/v1
2 kind: Deployment
3 metadata:
  name: prometheus-agent
   namespace: flashcat
    labels:
      app: prometheus-agent
  spec:
    replicas: 1
    selector:
      matchLabels:
        app: prometheus-agent
    template:
      metadata:
        labels:
          app: prometheus-agent
      spec:
        serviceAccountName: categraf
        containers:
          - name: prometheus
            image: prom/prometheus
            args:
              - "--config.file=/etc/prometheus/prometheus.yml"
               - "--web.enable-lifecycle"
               - "--enable-feature=agent"
            ports:
               - containerPort: 9090
```

```
resources:
               requests:
                 cpu: 500m
                 memory: 500M
               limits:
                 cpu: 1
                 memory: 1Gi
             volumeMounts:
               - name: prometheus-config-volume
                 mountPath: /etc/prometheus/
               - name: prometheus-storage-volume
                 mountPath: /prometheus/
           - name: prometheus-config-volume
41
             configMap:
               defaultMode: 420
               name: prometheus-agent-conf
           - name: prometheus-storage-volume
             emptyDir: {}
```

这里要注意的关键点,一个是 serviceAccountName,配置是 categraf,和前面创建的 ServiceAccount 对应,另一个是 args 部分,给出了相关的启动参数,--enable-feature=agent 就是作为 agent mode 模式运行。

最后,执行 kubectl apply -f prometheus-agent-deployment.yaml,让 Kubernetes 把 Deployment 拉起来就可以了。稍等片刻,去页面上查询一下 APIServer 的监 控数据,理论上是可以查到的,但是其他组件的监控数据,大概率是没有的,下面我们来一一 修复。

修复 Controller-manager 和 Scheduler

上面的抓取规则走的都是 Kubernetes 服务发现机制,发现 endpoint,然后过滤。我们先通过下面的命令查看一下 kube-system 这个 namespace 下有哪些 endpoint。

```
■ 复制代码

1 kubectl get endpoints -n kube-system
```

如果有 kube-controller-manager、kube-scheduler 这两个 endpoint, 理论上通过上面的抓取规则就可以抓到数据,如果没有的话,我们可以创建相关的 service。

你可以参考我给出的这两个 YAML 文件来创建 service。

- @https://github.com/flashcatcloud/categraf/blob/main/k8s/controller-service.yaml
- @https://github.com/flashcatcloud/categraf/blob/main/k8s/scheduler-service.yaml

另外就是得确保 Controller-manager 和 Scheduler 没有监听在 **127.0.0.1**,否则采集器落在其他机器上就访问不通了。具体怎么做呢?

在这两个组件的启动参数里加上 --bind-address=0.0.0.0 就可以了。如果是 Kubeadm 安装的,可以在 /etc/kubernetes/manifests/kube-controller-manager.yaml 和 /etc/kubernetes/manifests/kube-scheduler.yaml 里调整参数。调整完之后,理论上就可以抓到数据了。

修复 etcd

etcd 默认端口是 2379,如果从这个端口获取监控数据,就需要有比较复杂的认证鉴权。但其实 etcd 的监控数据也不是什么太关键的信息,而且是内网,直接开放就可以了。etcd 提供了一个启动参数,可以为暴露监控指标单独监听一个地址。

具体参数是:

1 --listen-metrics-urls=http://0.0.0.0:2381

1 复制代码

之后创建相关的 ⊘service ,prometheus agent 就可以发现这个 HTTP 的 endpoint 了。

修复 KSM

KSM 是监控各类 Kubernetes 对象的组件,通过 KSM 我们可以知道 Service、Deployment、Statefulset、Node 等组件的各类元信息,比如某个 Deployment 期望有几个副本、实际有几个 Pod 在运行这种问题,就是靠 KSM 来回答的。KSM 是如何知道这些信息的呢?它需要跟 APIServer 通信,订阅各类资源对象的变更。下面我们安装一下 KSM,相关指标就有了。

1 复制代码

KSM 在代码仓库里提供了相关的 YAML 文件,我们 clone 下来直接 apply 就可以。KSM 默认暴露了两个端口,8080 用于返回各类 Kubernetes 对象信息,8081 用于返回 KSM 自身的指标,我们在抓取规则里重点抓取的是8080 的数据。

KSM 要返回所有 Kubernetes 对象的指标,数据量比较大,从 8080 拉取监控数据可能会拉取十几秒甚至几十秒,KSM 为此支持了分片逻辑,examples/standard 下面提供的 YAML 文件是把 KSM 部署为单副本的 Deployment,分片的话使用 Daemonset,每个 Node 上都跑一个KSM,这个 KSM 只同步与自身节点相关的数据,KSM 的官方 README 里说得很清楚了,你可以看一下 Daemonset 样例。

```
国 复制代码
 1 apiVersion: apps/v1
2 kind: DaemonSet
3 spec:
    template:
       spec:
         containers:
         - image: registry.k8s.io/kube-state-metrics/kube-state-metrics:IMAGE_TAG
           name: kube-state-metrics
          args:
           - --resource=pods
           - --node=$(NODE_NAME)
          env:
           - name: NODE NAME
             valueFrom:
14
               fieldRef:
                 apiVersion: v1
                 fieldPath: spec.nodeName
17
```

另外,KSM 提供了两种方式来过滤要 watch 的对象类型,一个是通过白名单的方式指定具体要 watch 哪类对象,通过命令行启动参数中的 --

resources=daemonsets,deployments,表示只 watch daemonsets 和 deployments。虽然已经限制了对象资源类型,但如果采集的某些指标仍然不想要,可以采用黑名单的方式来过滤指标: --metric-denylist=kube_deployment_spec_.*。这个过滤规则支持正则写法,多个正则之间可以使用逗号分隔。

做完这些操作之后,我们就可以采集到这些组件的监控数据了,下面我们继续看哪些指标更为 关键。

关键指标

如果你使用 Grafana 来做可视化,可以参考下面两个项目中提供的 Dashboard。

- @https://github.com/kubernetes-monitoring/kubernetes-mixin
- @https://github.com/dotdc/grafana-dashboards-kubernetes

因为所有组件都是 Go 实现的,都暴露了 Go 程序通用的那些 CPU、内存、Goroutine、句柄等指标,这一部分内容我们在上一讲已经介绍过,这里不再赘述。下面我们分别看一下这几个组件一些其他类型的关键指标。

APIServer

APIServer 的核心职能是 Kubernetes 集群的 API 总入口,Kube-Proxy、Kubelet、Controller-Manager、Scheduler 等都需要调用 APIServer,所以 APIServer 的监控,完全按照 RED 方法论来梳理即可,最核心的就是请求吞吐和延迟。

- apiserver_request_total: 请求量的指标,可以统计每秒请求数、成功率。
- apiserver_request_duration_seconds: 请求耗时的指标。
- apiserver_current_inflight_requests: APIServer 当前处理的请求数,分为 mutating(非 get、list、watch 的请求)和 readOnly(get、list、watch 请求)两种,请求量过大就会被 限流,所以这个指标对我们观察容量水位很有帮助。

Controller-manager

Controller-manager 负责监听对象状态,并与期望状态做对比。如果状态不一致则进行调谐, 重点关注的是**任务数量、队列深度**等。

- workqueue_adds_total: 各个 controller 接收到的任务总数。
- workqueue_depth: 各个 controller 的队列深度,表示各个 controller 中的任务的数量,数量越大表示越繁忙。
- workqueue_queue_duration_seconds: 任务在队列中的等待耗时,按照控制器分别统计。
- workqueue_work_duration_seconds: 任务出队到被处理完成的时间,按照控制器分别统计。
- workqueue_retries_total: 任务进入队列的重试次数。

Scheduler

Scheduler 在 Kubernetes 架构中负责把对象调度到合适的 Node 上,在这个过程中会有一系列的规则计算和筛选,重点关注**调度**这个动作的相关指标。

- leader election master status: 调度器的选主状态, 1 表示 master, 0 表示 backup。
- scheduler_queue_incoming_pods_total: 进入调度队列的 Pod 数量。
- scheduler_pending_pods: Pending 的 Pod 数量。
- scheduler pod scheduling attempts: Pod 调度成功前,调度重试的次数分布。
- scheduler_framework_extension_point_duration_seconds: 调度框架的扩展点延迟分布, 按 extension_point 统计。
- scheduler_schedule_attempts_total:按照调度结果统计的尝试次数,"unschedulable"表示无法调度,"error"表示调度器内部错误。

etcd

etcd 在 Kubernetes 的架构中作用巨大,相对也比较稳定,不过 etcd 对硬盘 IO 要求较高,因此需要着重关注 IO 相关的指标,生产环境建议至少使用 SSD 的盘做存储。

- etcd server has leader: etcd 是否有 leader。
- etcd_server_leader_changes_seen_total: 偶尔切主问题不大, 频繁切主就要关注了。
- etcd_server_proposals_failed_total: 提案失败次数。
- etcd_disk_backend_commit_duration_seconds: 提交花费的耗时。

• etcd_disk_wal_fsync_duration_seconds: wal 日志同步耗时。

KSM

- kube_node_status_condition: Node 节点状态,状态不正常、有磁盘压力等都可以通过这个指标发现。
- kube_pod_container_status_last_terminated_reason: 容器停止原因。
- kube pod container status waiting reason: 容器处于 waiting 状态的原因。
- kube_pod_container_status_restarts_total: 容器重启次数。
- kube_deployment_spec_replicas: deployment 配置期望的副本数。
- kube_deployment_status_replicas_available: deployment 实际可用的副本数。

基于 KSM 数据的比较典型的告警规则,我也举个例子,让你有一个直观的认识。

上面我只是举了 Deployment 的例子,Statefulset 也是类似的。到这里控制面的核心组件以及 KSM 相关的知识就讲完了,下面我们做个总结。

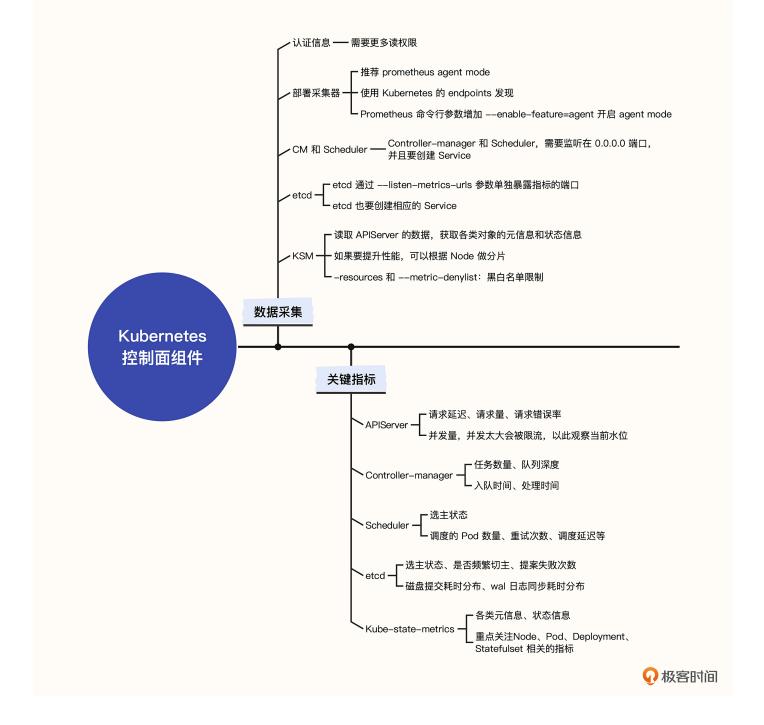
小结

Kubernetes 体系确实非常庞大,这一讲我们重点介绍控制面的组件监控,包括 APIServer、Controller-manager、Scheduler、etcd 等。当然,Kubernetes 对象的监控也很关键,可以使用 KSM 完成。

核心内容主要是两部分,一个是数据采集,一个是关键指标。数据采集我们引入了 prometheus agent mode,支持 Kubernetes 服务发现,非常轻量,通过 remote write 协议把数据推给后端存储。关键指标的话需要看各个模块的核心职能以及重点依赖,比如 Scheduler 是做调度的,那就要看调度相关的指标,etcd 强依赖硬盘,就要多关注硬盘 IO 相关的指标。

Kubernetes 控制面的组件全部都要认证鉴权,相比之前演示的 Kubelet 数据采集,需要给更多的权限。Controller-manager、Scheduler 可能默认没有创建 Service,需要手工创建并且修改监听地址,etcd 要开启 HTTP 协议的指标暴露端口,这些都是坑,需要依次修复。

关键指标部分我提供了一些最为常见的指标说明,你也可以参考监控大盘中的配置,指标既然放到大盘中了,就表示相对重要。不得不说,监控大盘是一个很好的知识沉淀的手段。



互动时刻

在 Prometheus 的抓取配置中,我们给出了几个抓取 Job 的配置。如果一个 Kubernetes 集群的数据只写入一个时序库,这样的配置是没问题,如果多个 Kubernetes 集群的数据都写入一个时序库,就要通过额外的标签来区分了。你知道如何为抓取的数据附加新的标签吗? 欢迎在评论区留下你的思考,也欢迎你把今天的内容分享给你身边的朋友,邀他一起学习。我们下一讲再见!

心 赞 6 2 提建议

© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 17 | 组件监控: Kubernetes Node组件的关键指标与数据采集

下一篇 19 | 应用监控:如何使用埋点方式对应用监控?

精选留言(5)





Geek 1a3949

2023-02-17 来自上海

尝试回答一下课后题:

可以为prometheus增加global.external labels配置,增加cluster的标识以区分不同的集群: global:

external labels:

cluster: prod-bigdata-sh

另外,请教老师一个问题,ksm的分片,官网上有statefulset、daemonset的分片方式,它们 各自的适用场景是什么,在生产环境下,更推荐哪种方式?

作者回复: 量小的话sts即可,量大的话得daemonset

L 4



胡飞

2023-03-15 来自上海

你好老师, promtheus 如果开启了remote write后,存储会用两份吗? prom本地一份数据,第 三方一份数据?

作者回复: 是的







自己做监控系统 但是用了公有云产品 比如华为云的k8s 请问怎么监控哈 公司都是用公有云sa as 自己公司卖paas产品

作者回复: 只用了一个云的话,其实直接用云的监控就可以了,未来要是有多云或者混合云的场景,再考虑自建监控。如果自己搞监控来监控K8s,主要关注工作负载节点就可以了,托管的K8s控制面组件的可靠性让云厂商来做





LiLian

2023-02-24 来自广东

请问老师: "prometheus agent mode, 支持 Kubernetes 服务发现"本质上还是通过list & wat ch 监听来自api server的信息吗?

作者回复: 是



peter

2023-02-18 来自北京

请教老师几个问题:

- Q1: KSM是k8s自身的组件吗?还是一个第三方的软件?
- **Q2**: 一般性的问题,公司的实际运营中,日志数据一般保存多长时间?指标数据一般保存多长时间?(到期后是直接删除数据吧)

作者回复: 1,不是,但可以看做是伴生的重要性

2,有些日志有政策审计要求,有些只查问题,有些用于做数据统计,日志保存时间都不一样,指标的话默认15天即可,一些业务指标可能会需要永久保存